



Anhanguera

Medidas de  
associação

Felipe  
Figueiredo

Regressão

Interpretação

Causalidade

Resumo

# Medidas de associação

## Regressão Linear Simples

Felipe Figueiredo

UNIAN - Centro Universitário Anhanguera de Niterói

- 1 Regressão Linear Simples
  - Modelos estatísticos
  - Coeficiente de Determinação  $r^2$
- 2 Interpretação
- 3 Causalidade
- 4 Resumo

- 1 Regressão Linear Simples
  - Modelos estatísticos
  - Coeficiente de Determinação  $r^2$
- 2 Interpretação
- 3 Causalidade
- 4 Resumo

Modelos servem para:

- representar de forma simplificada fenômenos, experimentos, dados, etc;
- possibilitar análise em cenários controlados, menos complexos que a realidade;
- extrapolar resultados e conclusões.

Modelos servem para:

- representar de forma simplificada fenômenos, experimentos, dados, etc;
- possibilitar análise em cenários controlados, menos complexos que a realidade;
- extrapolar resultados e conclusões.

Modelos servem para:

- representar de forma simplificada fenômenos, experimentos, dados, etc;
- possibilitar análise em cenários controlados, menos complexos que a realidade;
- extrapolar resultados e conclusões.

Ao ajustar um modelo aos dados, podemos:

- fazer previsões dentro do intervalo observado para dados que não foram obtidos (interpolação)
- fazer previsões fora do intervalo observado (extrapolação)

Ao ajustar um modelo aos dados, podemos:

- fazer predições dentro do intervalo observado para dados que não foram obtidos (interpolação)
- fazer predições fora do intervalo observado (extrapolação)



## Definition

Uma **reta de regressão** (também chamada de reta de melhor ajuste) é a reta para a qual a soma dos erros quadráticos dos resíduos é o mínimo.

- É a reta que melhor se ajusta aos dados
- Minimiza os resíduos

## Definition


Uma **reta de regressão** (também chamada de reta de melhor ajuste) é a reta para a qual a soma dos erros quadráticos dos resíduos é o mínimo.

- É a reta que melhor se ajusta aos dados
- Minimiza os resíduos

## Definition

Uma **reta de regressão** (também chamada de reta de melhor ajuste) é a reta para a qual a soma dos erros quadráticos dos resíduos é o mínimo.

- É a reta que melhor se ajusta aos dados
- Minimiza os resíduos



## Definition

Resíduos são a distância entre o dado observado e a reta estimada (modelo).

- Relembrando: a equação de uma reta é definida pela fórmula

$$\hat{y} = ax + b$$

- No caso da reta regressora:
  - $y$  é a variável dependente
  - $x$  é a variável independente
  - $a$  é a inclinação
  - $b$  é o intercepto
- Assim, o objetivo da análise de regressão é encontrar os valores  $a$  e  $b$

- Relembrando: a equação de uma reta é definida pela fórmula

$$\hat{y} = ax + b$$

- No caso da reta regressora:
  - $y$  é a variável dependente
  - $x$  é a variável independente
  - $a$  é a inclinação
  - $b$  é o intercepto
- Assim, o objetivo da análise de regressão é encontrar os valores  $a$  e  $b$

- Relembrando: a equação de uma reta é definida pela fórmula

$$\hat{y} = ax + b$$

- No caso da reta regressora:
  - $y$  é a variável dependente
  - $x$  é a variável independente
  - $a$  é a inclinação
  - $b$  é o intercepto
- Assim, o objetivo da análise de regressão é encontrar os valores  $a$  e  $b$

- Relembrando: a equação de uma reta é definida pela fórmula

$$\hat{y} = ax + b$$

- No caso da reta regressora:
  - $y$  é a variável dependente
  - $x$  é a variável independente
  - $a$  é a inclinação
  - $b$  é o intercepto
- Assim, o objetivo da análise de regressão é encontrar os valores  $a$  e  $b$



- Relembrando: a equação de uma reta é definida pela fórmula

$$\hat{y} = ax + b$$

- No caso da reta regressora:
  - $y$  é a variável dependente
  - $x$  é a variável independente
  - $a$  é a inclinação
  - $b$  é o intercepto
- Assim, o objetivo da análise de regressão é encontrar os valores  $a$  e  $b$

- Relembrando: a equação de uma reta é definida pela fórmula

$$\hat{y} = ax + b$$

- No caso da reta regressora:
  - $y$  é a variável dependente
  - $x$  é a variável independente
  - $a$  é a inclinação
  - $b$  é o intercepto
- Assim, o objetivo da análise de regressão é encontrar os valores  $a$  e  $b$

- Relembrando: a equação de uma reta é definida pela fórmula

$$\hat{y} = ax + b$$

- No caso da reta regressora:
  - $y$  é a variável dependente
  - $x$  é a variável independente
  - $a$  é a inclinação
  - $b$  é o intercepto
- Assim, o objetivo da análise de regressão é encontrar os valores  $a$  e  $b$

Para determinar a inclinação e o intercepto, usamos:

- as médias de  $X$  e  $Y$
- as variâncias de  $X$  e  $Y$
- o coeficiente de correlação  $r$  entre  $X$  e  $Y$
- o tamanho da amostra  $n$
- ... e algumas operações entre estes termos

Para determinar a inclinação e o intercepto, usamos:

- as médias de  $X$  e  $Y$
- as variâncias de  $X$  e  $Y$
- o coeficiente de correlação  $r$  entre  $X$  e  $Y$
- o tamanho da amostra  $n$
- ... e algumas operações entre estes termos

Para determinar a inclinação e o intercepto, usamos:

- as médias de  $X$  e  $Y$
- as variâncias de  $X$  e  $Y$
- o coeficiente de correlação  $r$  entre  $X$  e  $Y$
- o tamanho da amostra  $n$
- ... e algumas operações entre estes termos


Para determinar a inclinação e o intercepto, usamos:

- as médias de  $X$  e  $Y$
- as variâncias de  $X$  e  $Y$
- o coeficiente de correlação  $r$  entre  $X$  e  $Y$
- o tamanho da amostra  $n$
- ... e algumas operações entre estes termos

Para determinar a inclinação e o intercepto, usamos:

- as médias de  $X$  e  $Y$
- as variâncias de  $X$  e  $Y$
- o coeficiente de correlação  $r$  entre  $X$  e  $Y$
- o tamanho da amostra  $n$
- ... e algumas operações entre estes termos





- A qualidade do ajuste do modelo de regressão é determinado pelo **coeficiente de determinação**  $r^2$

- 1 Regressão Linear Simples
  - Modelos estatísticos
  - Coeficiente de Determinação  $r^2$
- 2 Interpretação
- 3 Causalidade
- 4 Resumo

# Coeficiente de Determinação $r^2$



Anhanguera

Medidas de  
associação

Felipe  
Figueiredo

Regressão

Modelos estatísticos  
 $R^2$

Interpretação

Causalidade

Resumo

## Definition

O **coeficiente de determinação**  $r^2$  é a relação da variação explicada com a variação total.

$$r^2 = \frac{\text{variação explicada}}{\text{variação total}}$$

- Lembrando:  $r^2$  é o quadrado de  $r$ !

# Coeficiente de Determinação $r^2$

## Definition

O **coeficiente de determinação**  $r^2$  é a relação da variação explicada com a variação total.

$$r^2 = \frac{\text{variação explicada}}{\text{variação total}}$$

- Lembrando:  $r^2$  é o quadrado de  $r$ !

# Coefficiente de Determinação $r^2$



Anhanguera

Medidas de  
associação

Felipe  
Figueiredo

Regressão

Modelos estatísticos  
 $R^2$

Interpretação

Causalidade

Resumo

- Qual é a porcentagem da variação dos dados pode ser explicada pela reta regressora?
- O coeficiente  $r^2$  é a fração da variância que é compartilhada entre  $X$  e  $Y$ .
- Como  $r$  está sempre entre -1 e 1,  $r^2$  está sempre entre 0 e 1.

# Coefficiente de Determinação $r^2$



Anhanguera

Medidas de  
associação

Felipe  
Figueiredo

Regressão

Modelos estatísticos  
 $R^2$

Interpretação

Causalidade

Resumo

- Qual é a porcentagem da variação dos dados pode ser explicada pela reta regressora?
- O coeficiente  $r^2$  é a fração da variância que é compartilhada entre  $X$  e  $Y$ .
- Como  $r$  está sempre entre -1 e 1,  $r^2$  está sempre entre 0 e 1.

# Coefficiente de Determinação $r^2$

- Qual é a porcentagem da variação dos dados pode ser explicada pela reta regressora?
- O coeficiente  $r^2$  é a fração da variância que é compartilhada entre  $X$  e  $Y$ .
- Como  $r$  está sempre entre -1 e 1,  $r^2$  está sempre entre 0 e 1.

# Coefficiente de Determinação $r^2$

- Além disso,  $r^2 \leq |r|$

- Por que?

Compare os seguintes números entre 0 e 1:

$$\frac{1}{2} \text{ e } \left(\frac{1}{2}\right)^2 = \frac{1}{4} \Rightarrow \frac{1}{4} \leq \frac{1}{2}$$

$$\frac{1}{3} \text{ e } \left(\frac{1}{3}\right)^2 = \frac{1}{9} \Rightarrow \frac{1}{9} \leq \frac{1}{3}$$





# Coefficiente de Determinação $r^2$

- Além disso,  $r^2 \leq |r|$
- Por que?

Compare os seguintes números entre 0 e 1:

$$\frac{1}{2} \text{ e } \left(\frac{1}{2}\right)^2 = \frac{1}{4} \Rightarrow \frac{1}{4} \leq \frac{1}{2}$$

$$\frac{1}{3} \text{ e } \left(\frac{1}{3}\right)^2 = \frac{1}{9} \Rightarrow \frac{1}{9} \leq \frac{1}{3}$$

- Se a correlação é 0, então X e Y não variam juntos (independentes)
- Se a correlação é positiva, então quando uma aumenta, a outra aumenta em proporção direta (linear)
- Se a correlação é negativa, então quando uma aumenta, a outra diminui em proporção inversa (linear)

- Se a correlação é 0, então X e Y não variam juntos (independentes)
- Se a correlação é positiva, então quando uma aumenta, a outra aumenta em proporção direta (linear)
- Se a correlação é negativa, então quando uma aumenta, a outra diminui em proporção inversa (linear)

- Se a correlação é 0, então X e Y não variam juntos (independentes)
- Se a correlação é positiva, então quando uma aumenta, a outra aumenta em proporção direta (linear)
- Se a correlação é negativa, então quando uma aumenta, a outra diminui em proporção inversa (linear)

- Duas variáveis podem **parecer** correlacionadas pois são influenciadas por uma terceira variável
- Ex: em alguns países a mortalidade infantil é negativamente correlacionada com o número de telefones per capita
- Mas comprar mais telefones não vai salvar crianças!
- Explicação alternativa: a melhoria da condições financeiras pode afetar ambas as variáveis

- Duas variáveis podem **parecer** correlacionadas pois são influenciadas por uma terceira variável
- Ex: em alguns países a mortalidade infantil é negativamente correlacionada com o número de telefones per capita
- Mas comprar mais telefones não vai salvar crianças!
- Explicação alternativa: a melhoria da condições financeiras pode afetar ambas as variáveis

- Duas variáveis podem **parecer** correlacionadas pois são influenciadas por uma terceira variável
- Ex: em alguns países a mortalidade infantil é negativamente correlacionada com o número de telefones per capita
- Mas comprar mais telefones não vai salvar crianças!
- Explicação alternativa: a melhoria da condições financeiras pode afetar ambas as variáveis



- Duas variáveis podem **parecer** correlacionadas pois são influenciadas por uma terceira variável
- Ex: em alguns países a mortalidade infantil é negativamente correlacionada com o número de telefones per capita
- Mas comprar mais telefones não vai salvar crianças!
- Explicação alternativa: a melhoria da condições financeiras pode afetar ambas as variáveis

- Se há uma relação de causalidade entre as duas variáveis, a correlação será não nula (positiva ou negativa)
- Quanto maior for a relação de dependência entre as variáveis, maior será o módulo da correlação.
- Se as variáveis não são relacionadas, a correlação será nula.

- Se há uma relação de causalidade entre as duas variáveis, a correlação será não nula (positiva ou negativa)
- Quanto maior for a relação de dependência entre as variáveis, maior será o módulo da correlação.
- Se as variáveis não são relacionadas, a correlação será nula.



- Se há uma relação de causalidade entre as duas variáveis, a correlação será não nula (positiva ou negativa)
- Quanto maior for a relação de dependência entre as variáveis, maior será o módulo da correlação.
- Se as variáveis não são relacionadas, a correlação será nula.

- Mas não podemos inverter a afirmativa lógica do slide anterior!
- Isto é, ao observar uma forte correlação, gostaríamos de concluir que uma variável **causa** este efeito na outra
- Infelizmente isto não é possível!
- Lembre-se: a significância do teste indica a probabilidade de se cometer um erro do tipo I (falso positivo).

Repita várias vezes mentalmente

Correlação não implica em causalidade.

- Mas não podemos inverter a afirmativa lógica do slide anterior!
- Isto é, ao observar uma forte correlação, gostaríamos de concluir que uma variável **causa** este efeito na outra
- Infelizmente isto não é possível!
- Lembre-se: a significância do teste indica a probabilidade de se cometer um erro do tipo I (falso positivo).

Repita várias vezes mentalmente

Correlação não implica em causalidade.

- Mas não podemos inverter a afirmativa lógica do slide anterior!
- Isto é, ao observar uma forte correlação, gostaríamos de concluir que uma variável **causa** este efeito na outra
- Infelizmente isto não é possível!
- Lembre-se: a significância do teste indica a probabilidade de se cometer um erro do tipo I (falso positivo).

Repita várias vezes mentalmente

Correlação não implica em causalidade.

- ### Medidas de associação

Felipe Figueiredo

## Regressão

### Interpretação

## Causalidade

## Resumo



- Mas não podemos inverter a afirmativa lógica do slide anterior!
- Isto é, ao observar uma forte correlação, gostaríamos de concluir que uma variável **causa** este efeito na outra
- Infelizmente isto não é possível!
- Lembre-se: a significância do teste indica a probabilidade de se cometer um erro do tipo I (falso positivo).

Repita várias vezes mentalmente

Correlação não implica em causalidade.

# Exemplo

Medidas de  
associação

Felipe  
Figueiredo


Regressão

Interpretação

Causalidade

Resumo

## Gasto com C&T (EUA) x Suicídios por enforcamento



Correlação: 0.992082  
(Fonte: Spurious correlations)

# Exemplo

Medidas de  
associação

Felipe  
Figueiredo


Regressão

Interpretação

Causalidade

Resumo

## Produção de mel x Prisões por posse de maconha



Correlação: -0.933389  
(Fonte: Spurious correlations)

# Exemplo

Medidas de  
associação

Felipe  
Figueiredo


Regressão

Interpretação

Causalidade

Resumo

## Afogamentos em piscina x Filmes com Nicholas Cage



Correlação: 0.666004  
(Fonte: Spurious correlations)

Ao encontrar uma forte correlação, deve-se sempre se perguntar:

- 1 Há uma relação direta de causa e efeito entre as variáveis? (X causa Y?)
- 2 Há uma relação inversa de causa e efeito entre as variáveis? (Y causa X?)
- 3 É possível que a relação entre as variáveis possa ser causada por uma terceira variável (ou mais) que não foi analisada?
- 4 É possível que a relação entre duas variáveis seja uma coincidência?

Ao encontrar uma forte correlação, deve-se sempre se perguntar:

- 1 Há uma relação direta de causa e efeito entre as variáveis? (X causa Y?)
- 2 Há uma relação inversa de causa e efeito entre as variáveis? (Y causa X?)
- 3 É possível que a relação entre as variáveis possa ser causada por uma terceira variável (ou mais) que não foi analisada?
- 4 É possível que a relação entre duas variáveis seja uma coincidência?

Ao encontrar uma forte correlação, deve-se sempre se perguntar:

- 1 Há uma relação direta de causa e efeito entre as variáveis? (X causa Y?)
- 2 Há uma relação inversa de causa e efeito entre as variáveis? (Y causa X?)
- 3 É possível que a relação entre as variáveis possa ser causada por uma terceira variável (ou mais) que não foi analisada?
- 4 É possível que a relação entre duas variáveis seja uma coincidência?

Ao encontrar uma forte correlação, deve-se sempre se perguntar:

- 1 Há uma relação direta de causa e efeito entre as variáveis? (X causa Y?)
- 2 Há uma relação inversa de causa e efeito entre as variáveis? (Y causa X?)
- 3 É possível que a relação entre as variáveis possa ser causada por uma terceira variável (ou mais) que não foi analisada?
- 4 É possível que a relação entre duas variáveis seja uma coincidência?



- É necessário investigar a relação entre as variáveis!
- O que pode explicar a relação observada?
- Qual proporção (porcentagem) da variabilidade pode ser explicada pelas variáveis analisadas?
- Quão bem a reta regressora se ajusta aos dados?

- É necessário investigar a relação entre as variáveis!
- O que pode explicar a relação observada?
- Qual proporção (porcentagem) da variabilidade pode ser explicada pelas variáveis analisadas?
- Quão bem a reta regressora se ajusta aos dados?

- É necessário investigar a relação entre as variáveis!
- O que pode explicar a relação observada?
- Qual proporção (porcentagem) da variabilidade pode ser explicada pelas variáveis analisadas?
- Quão bem a reta regressora se ajusta aos dados?



- É necessário investigar a relação entre as variáveis!
- O que pode explicar a relação observada?
- Qual proporção (porcentagem) da variabilidade pode ser explicada pelas variáveis analisadas?
- Quão bem a reta regressora se ajusta aos dados?